


DESPLIEGUE DE MODELO DE MACHINE LEARNING



Detección de Fraudes en Tarjetas de Crédito
Grupo 1

INTRODUCCIÓN

Reemplazo del modelo de detección de fraudes con uno más preciso, entrenado con datos recientes. Sistema crítico 24/7.

FALSOS POSITIVOS
Bloqueos legítimos
Clientes molestos

FALSOS NEGATIVOS
Fraudes no detectados
Pérdidas económicas

MATERIALES Y MÉTODOS

Kubernetes **MLflow** **Prometheus**

Jenkins **TensorFlow** **Istio**

ML Model as a Service

<100ms> 1000 24/7

Latencia TPS Disponible

Infraestructura Cloud

Docker **AWS/Azure**

Terraform **API Gateway**

ARTEFACTOS

- Modelo: fraud_model_v2.3.pkl
- Rollback: v2.2
- Preprocessor: scaler_v2.3

PREREQUISITOS

Cluster K8s - Feature Store actualizado -
Validación staging - Backup v2.2 completo

ESTRATEGIA

CANARY DEPLOYMENT
Despliegue progresivo y controlado

5%

Fase Canary
Monitoreo Intensivo

25%

Fase Gradual
Según métricas

50%

Fase Expansión
Mayor volumen

Rollout 100%
Validación exitosa

Minimiza Riesgo

✓ Validación real
✓ Impacto limitado
✓ Rollback rápido
✓ Sin downtime

PROCESOS

Comunicación

Entorno Destino

Roles Involucrados

- Pre-deploy
- Post-deploy
- ML Engineer: preparación modelo
- DevOps: infraestructura
- SRE: monitoreo 24/7
- Product Owner: aprobación
- Fraud Analyst: validación

Producción Cloud
(AWS/Azure)

RESULTADOS

Despliegue exitoso
Sin downtime

HORARIO

Domingo 02:00 - 06:00
60% menos tráfico

Validaciones

p95
<100ms

FPR
<2%

FNR
<0.5%

TPS
>1000

Monitoreo 24/7

✓ Métricas técnicas
✓ Métricas ML
✓ Métricas negocio
✓ Data drift

Rollback Automático
< 5 min
Tiempo de respuesta.

SEGURIDAD

Auth **Encrypt** **Comply**

OAuth 2.0 - JWT - RBAC - mTLS - TLS
1.3 - AES-256 - Tokenization - PCI-DSS -
Audit Trail

DEVOPS / MLOPS

SCM
Git + DVC + MLflow

CI/CD
Pipeline automatizado

Continuous
Training + Monitoring

IaC
Terraform

CONCLUSIONES

- ✓ Canary Deployment minimiza riesgo con validación progresiva
- ✓ Monitoreo continuo detecta degradación del modelo
- ✓ Automatización MLOps garantiza despliegues auditables
- ✓ Balance perfecto entre validación y continuidad operativa

REFERENCIAS

- Sculley, D. et al. (2015). Hidden Technical Debt in Machine Learning Systems. NIPS.
- Humble, J. & Farley, D. (2010). Continuous Delivery. Addison-Wesley.
- Breck, E. et al. (2017). The ML Test Score. Google.
- Kubernetes Documentation. Performing a Rolling Update.
- AWS Well-Architected Framework - ML Lens (2023).